

Universidad de Costa Rica

Escuela de Ciencias de la Computación e Informática

CI1031 — Diseño de Experimentos

I Ciclo 2026

Laboratorio #7

Laboratorio de regresión lineal

Profesor: Ignacio Díaz Oreiro

Estudiante(s):

Christopher Zuniga (C228730)

Mario Cordero (C22306)

24 de junio de 2026

Índice

1. Primera parte: Análisis exploratorio y modelo de regresión lineal simple	2
1.1. Suma de residuos al cuadrado	3
1.2. El modelo lineal	4
1.3. Comprobación de supuestos	5
2. Segunda parte: Evaluación de otras variables predictoras	7
3. Tercera parte: Regresión lineal múltiple	10

1. Primera parte: Análisis exploratorio y modelo de regresión lineal simple

En esta sección se cargan los datos de la temporada 2011 de las Grandes Ligas de Béisbol y se explora la relación entre las carreras anotadas (runs) y los turnos al bate (at_bats)

```
# Carga de datos
beis <- read.csv(file.choose(), header = TRUE, encoding = "UTF-8")
attach(beis)

# Grafico de dispersion
plot(beis$at_bats, beis$runs)
```




Figura 1: Gráfico de dispersión entre turnos al bate (at_bats) y carreras anotadas (runs).

Pregunta y Respuesta

Pregunta 1: ¿La relación parece lineal?

A simple vista, la relación parece tener una **tendencia lineal positiva**, aunque con una dispersión considerable. Se puede observar que a medida que aumentan los turnos al bate (at_bats), existe una tendencia general a que aumenten las carreras anotadas (runs). Sin embargo, los puntos no se agrupan de forma estrecha alrededor de una línea recta teórica, lo que sugiere que la correlación, aunque lineal, podría ser moderada o débil.

También se puede cuantificar la fuerza de la relación con el coeficiente de correlación.

```
# Coeficiente de correlacion
cor(beis$runs, beis$at_bats)
```

Resultado:

```
> cor(beis$runs, beis$at_bats)
[1] 0.610627
```

Pregunta y Respuesta

Pregunta 2: ¿Qué tan fuerte es la correlación entre runs y at_bats?

El coeficiente de correlación obtenido es de aproximadamente **0.611**. En términos estadísticos, este valor indica la existencia de una **correlación lineal positiva moderada** entre los turnos al bate (at_bats) y las carreras anotadas (runs).

Esto significa que existe una tendencia real a que los equipos con más turnos al bate anoten más carreras, pero la fuerza de esta relación no es perfecta ni contundente, lo cual concuerda con la dispersión de los puntos observada en el gráfico anterior.

1.1. Suma de residuos al cuadrado

```
if(!require('statsr')) {
  install.packages('statsr')
  library('statsr')
}
plot_ss(x = at_bats, y = runs, data = beis, showSquares = TRUE)
```

Pregunta y Respuesta

Pregunta 3: Usando plot_ss, elija una línea que minimice lo más posible la suma de los cuadrados. ¿Cuál fue la menor suma de cuadrados que obtuvo? Para la suma de cuadrados más pequeña que encontró, incluya el gráfico resultante y también los resultados que aparecen en la consola.

Tras ejecutar la función interactiva varias veces y buscar la línea de mejor ajuste visual, la menor suma de cuadrados (*Sum of Squares*) que logré obtener fue de **125411.6**.




Figura 2: Línea de ajuste manual para minimizar la suma de cuadrados de los residuos.

Salida en R:

```
> plot_ss(x = at_bats, y = runs, data = beis, showSquares = TRUE)

Call:
lm(formula = y ~ x, data = pts)

Coefficients:
(Intercept)          x
-3134.5857         0.6941

Sum of Squares: 125411.6
```

1.2. El modelo lineal

```
# Ajuste del modelo lineal
m1 <- lm(runs ~ at_bats, data = beis)
summary(m1)
```

Salida en R:

```
> summary(m1)

Call:
lm(formula = runs ~ at_bats, data = beis)

Residuals:
    Min       1Q   Median       3Q      Max
-125.58  -47.05  -16.59   54.40  176.87

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -2789.2429   853.6957  -3.267  0.002871 **
at_bats       0.6305     0.1545    4.080  0.000339 ***
---
Signif. codes:  0   ***    0.001   **    0.01   *    0.05   .    0.1    1

Residual standard error: 66.47 on 28 degrees of freedom
Multiple R-squared:  0.3729,    Adjusted R-squared:  0.3505
F-statistic: 16.65 on 1 and 28 DF,  p-value: 0.0003388
```

Pregunta y Respuesta

Pregunta 4: Escriba la fórmula del modelo lineal obtenido con los valores correctos de pendiente e intersección con el eje y.

A partir de la salida generada por el `summary()` del modelo, los coeficientes estimados son los siguientes:

- **Intersección con el eje y (β_0):** -2789.2429
- **Pendiente (β_1):** 0.6305

Sustituyendo estos valores, la fórmula del modelo lineal se expresa de la siguiente manera:

$$\hat{y} = -2789,2429 + 0,6305 \cdot at_bats$$

Esto significa que, según el modelo, por cada turno al bate adicional (`at_bats`), el equipo anota en promedio 0.6305 carreras adicionales.

Ahora se creará un diagrama de dispersión agregando la línea de mínimos cuadrados.




Figura 3: Diagrama de dispersión de carreras anotadas vs. turnos al bate, incluyendo la línea de regresión ajustada obtenida del modelo m1.

Análisis del ajuste: Como podemos ver en la Figura 3, la línea de regresión pasa justo por el medio del grupo de datos, lo que nos confirma visualmente que sí existe una tendencia de subida y una relación moderada entre ambas variables. En otras palabras, esta línea es la mejor predicción que nuestro modelo puede hacer. Si medimos la distancia vertical desde cualquier punto hasta la línea negra, estamos viendo el margen de error de esa predicción (*es decir, el residuo*). Por lo tanto, entre más pegado esté un punto a la recta, más exacta fue la predicción del modelo para ese equipo.

1.3. Comprobación de supuestos

```
# Verificación de la normalidad de residuales
shapiro.test(m1$residuals)

# Verificación de homocedasticidad
library(car)
bptest(m1)

# Verificación visual de la independencia
plot(m1$residuals)
abline(h = 0, col = "red", lwd = 1)
```

Resultados:

```
> # ----- Normalidad
> shapiro.test(m1$residuals)

      Shapiro-Wilk normality test

data:  m1$residuals
W = 0.96144, p-value = 0.337

> # ----- Homocedasticidad
> library(car)
> ncvtTest(m1)
Non-constant Variance Score Test
Variance formula: ~ fitted.values
Chisquare = 0.01429033, Df = 1, p = 0.90485
```




Figura 4: Distribución de los residuales del modelo lineal simple versus el índice de observación.

Pregunta y Respuesta

Pregunta 5: Verifique la normalidad, la homocedasticidad y la independencia de los residuales. ¿Se cumplen estos supuestos?

De acuerdo con las pruebas estadísticas y la inspección visual ejecutada (evaluadas con un nivel de significancia del 5%), se confirma que el modelo cumple satisfactoriamente con los tres supuestos fundamentales de la regresión lineal:

- **¿Se cumple la normalidad de los residuales?:** Sí. La prueba de Shapiro-Wilk arrojó un p-value de 0.337. Al ser superior a 0.05, no existe evidencia estadística para rechazar la hipótesis nula, por lo que se asume que los residuales siguen una distribución normal.
- **¿Se cumple la homocedasticidad de los residuales?:** Sí. La prueba de varianza no constante (ncvTest) arrojó un p-value de 0.90485. Al ser un valor muy por encima del nivel de significancia de 0.05, se acepta la hipótesis nula de que la varianza de los residuos se mantiene constante y homogénea a lo largo de las observaciones.
- **¿Se cumple la independencia de los residuales?:** Sí. Al analizar el gráfico de residuales en el tiempo (indexados), los puntos se distribuyen de manera aleatoria y sin ningún patrón discernible alrededor del eje central (0). Esta dispersión caótica indica que no existe autocorrelación entre los errores de las distintas observaciones, confirmando su independencia.

2. Segunda parte: Evaluación de otras variables predictoras

Pregunta y Respuesta

Pregunta 6: Ajuste un nuevo modelo de regresión lineal que use homeruns para predecir runs en vez de at_bats. Muestre el código R usado para crear el modelo y la salida `summary()` de ese modelo.

```
# Ajuste del nuevo modelo lineal usando homeruns como predictor
m2 <- lm(runs ~ homeruns, data = beis)

# Mostrar el resumen estadístico del modelo
summary(m2)
```

Salida en la consola de R:

```
> summary(m2)

Call:
lm(formula = runs ~ homeruns, data = beis)

Residuals:
    Min       1Q   Median       3Q      Max
-91.615 -33.410   3.231  24.292 104.631

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 415.2389    41.6779   9.963 1.04e-10 ***
homeruns      1.8345     0.2677   6.854 1.90e-07 ***
---
Signif. codes:  0   ***    0.001   **   0.01   *   0.05   .   0.1   1

Residual standard error: 51.29 on 28 degrees of freedom
Multiple R-squared:  0.6266,    Adjusted R-squared:  0.6132
F-statistic: 46.98 on 1 and 28 DF, p-value: 1.9e-07
```

Pregunta y Respuesta

Pregunta 7: Usando los coeficientes del `summary()` anterior, escriba la ecuación del modelo (la línea de regresión).

A partir de la salida generada por el `summary()` del modelo, se extraen los coeficientes estimados:

- **Intersección con el eje y (β_0):** 415.2389
- **Pendiente (β_1):** 1.8345

Sustituyendo estos valores, la ecuación de la línea de regresión se expresa de la siguiente manera:

$$\hat{y} = 415,2389 + 1,8345 \cdot \text{homeruns}$$

Esto indica que el modelo establece una base proyectada de aproximadamente 415 carreras, y predice que por cada jonrón (homeruns) adicional, el equipo anotará en promedio 1.8345 carreras más.

Pregunta y Respuesta

Pregunta 8: ¿Qué nos dice El Múltiple R-Cuadrado de este modelo con homeruns en comparación con el modelo anterior (para at_bats)? ¿Cuál predice mejor los resultados?

El Múltiple R-Cuadrado (R^2) nos indica la proporción de la varianza en la variable de respuesta (runs) que es explicada matemáticamente por la variable predictora.

Al comparar ambos modelos, observamos una diferencia significativa en su capacidad explicativa:

- El modelo que utiliza at_bats arrojó un R^2 de **0.3729**, lo que significa que los turnos al bate solo explican el 37.29 % de la variabilidad en las carreras anotadas.
- El modelo que utiliza homeruns arrojó un R^2 de **0.6266**, indicando que los jonrones logran explicar el 62.66 % de dicha variabilidad.

En conclusión, **el modelo basado en homeruns predice mucho mejor los resultados**. Al tener un R^2 considerablemente mayor, demuestra ser un predictor mucho más robusto y confiable para estimar la cantidad de carreras (runs) de un equipo en comparación con los turnos al bate.

Pregunta y Respuesta

Pregunta 9: Ahora que sabe analizar la relación lineal entre dos variables (creando modelos de regresión lineal), investigue las relaciones entre runs y cada una de las variables tradicionales (at_bats, hits, homeruns, bat_avg, strikeouts, stolen_bases, y wins). Ya ha generado la información para at_bats y homeruns.

Tabla de comparación de variables predictoras

Variable predictora	Correlación	p-value del Modelo	R^2
at_bats	0.6106	3.39e-04	0.3729
hits	0.8012	1.04e-07	0.6419
homeruns	0.7916	1.90e-07	0.6266
bat_avg	0.8100	5.88e-08	0.6561
strikeouts	-0.4115	2.39e-02	0.1694
stolen_bases	0.0540	7.77e-01	0.0029
wins	0.6008	4.47e-04	0.3610

Descripción de las métricas evaluadas:

- **Variable predictora:** La estadística de béisbol específica (X) que se está evaluando para intentar predecir la cantidad de carreras anotadas (Y).
- **Correlación (r):** Mide la dirección y la fuerza de la relación lineal entre ambas variables. Un valor cercano a 1 indica una relación positiva fuerte, mientras que un valor cercano a -1 indica una relación inversa.
- **p-value del Modelo:** Indica la significancia estadística de la regresión. Un valor inferior al nivel de significancia ($\alpha = 0,05$) confirma que la variable aporta información válida y que la relación no es producto del azar.
- **R^2 (Múltiple R-Cuadrado):** Representa la proporción o porcentaje de la variabilidad total en las carreras anotadas que logra ser explicada matemáticamente por la variable predictora.

Pregunta y Respuesta

Pregunta 10: ¿Cuál de las siete variables anteriores predice mejor la variable runs y por qué lo considera usted así?

De acuerdo con los resultados obtenidos en la tabla comparativa, la variable que predice mejor las carreras anotadas (runs) es el promedio de bateo (bat_avg).

Esta conclusión se sustenta de manera objetiva en tres indicadores estadísticos fundamentales:

- **Mayor R^2 :** Presenta el coeficiente de determinación más alto de la tabla (0.6561), lo que significa que el promedio de bateo es capaz de explicar el 65.61 % de la variabilidad en las carreras anotadas.
- **Correlación más fuerte:** Su coeficiente de correlación (0.8100) es el más cercano a 1 de todas las opciones, indicando la relación lineal positiva más robusta.
- **Mayor significancia (p-value mínimo):** Su p-value ($5,88 \times 10^{-8}$) es el más pequeño, confirmando de manera contundente que el modelo es estadísticamente significativo.

Nota: Le siguen muy de cerca hits ($R^2 = 0.6419$) y homeruns ($R^2 = 0.6266$) como excelentes predictores, mientras que variables como las bases robadas (stolen_bases) demostraron ser prácticamente inútiles para predecir las carreras, con un R^2 de apenas 0.0029 y un p-value (0.777) que no permite rechazar la hipótesis nula.

3. Tercera parte: Regresión lineal múltiple

Modelo de regresión lineal con cinco de las variables originales: at_bats, hits, homeruns, bat_avg, y wins.

```
mul <- lm(runs ~ at_bats + hits + homeruns + bat_avg + wins, data = beis)
summary(mul)
```

Salida en R:

```
> summary(mul)

Call:
lm(formula = runs ~ at_bats + hits + homeruns + bat_avg + wins,
    data = beis)

Residuals:
    Min       1Q   Median       3Q      Max
-48.744 -22.859  -5.446   21.876   59.388

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2583.4214   4006.8878    0.645  0.52521
at_bats       -0.5402     0.7256   -0.745  0.46380
hits          2.2542     2.8344    0.795  0.43424
homeruns       1.0412     0.2442    4.264  0.00027 ***
bat_avg     -9059.2528  15769.7868   -0.574  0.57100
wins           0.8610     0.7611    1.131  0.26914
---
Signif. codes:  0   ***   0.001   **   0.01   *   0.05   .   0.1   1

Residual standard error: 31.3 on 24 degrees of freedom
Multiple R-squared:  0.8808,    Adjusted R-squared:  0.856
F-statistic: 35.47 on 5 and 24 DF,  p-value: 2.504e-10
```

Pregunta y Respuesta

Pregunta 11: Con base en el resultado anterior, construya la fórmula del modelo de regresión lineal que corresponde a estas cinco variables.

A partir de la salida generada por el `summary()` del modelo, se extraen los coeficientes estimados:

- **Intersección con el eje y (β_0):** 2583.4214
- **Pendiente para at_bats (β_1):** -0.5402
- **Pendiente para hits (β_2):** 2.2542
- **Pendiente para homeruns (β_3):** 1.0412
- **Pendiente para bat_avg (β_4):** -9059.2528
- **Pendiente para wins (β_5):** 0.8610

Sustituyendo estos valores, la ecuación del modelo de regresión se expresa de la siguiente manera:

$$\hat{y} = 2583,4214 - 0,5402 \cdot \text{at_bats} + 2,2542 \cdot \text{hits} + 1,0412 \cdot \text{homeruns} - 9059,2528 \cdot \text{bat_avg} + 0,8610 \cdot \text{wins}$$

Esto indica que el modelo establece una base proyectada de aproximadamente 2583 carreras, y predice, por ejemplo, que por cada hit (hits) adicional (manteniendo las demás variables constantes), el equipo anotará en promedio 2.2542 carreras más.

Pregunta y Respuesta

Pregunta 12: Según los resultados, ¿el modelo de regresión lineal es significativo? ¿Cómo puede determinarlo?

Sí, el modelo de regresión lineal múltiple en su conjunto es estadísticamente significativo. Esto se determina observando el **p-value global del modelo** ubicado en la última línea de la salida, asociado al estadístico F (*F-statistic*). El valor obtenido es de $2,504 \times 10^{-10}$. Al ser un valor microscópico y abrumadoramente menor que el nivel de significancia típico de $\alpha = 0,05$, se rechaza fuertemente la hipótesis nula. Esto nos confirma que al menos una de las variables predictoras incluidas aporta información real y significativa para predecir las carreras anotadas (runs).

Pregunta y Respuesta

Pregunta 13: Según los resultados del `summary(mul)`, ¿cuánto porcentaje de la variabilidad de la variable de respuesta es atribuible al modelo de regresión lineal? ¿Es este modelo de regresión múltiple un mejor predictor que el mejor modelo de regresión lineal simple de la Pregunta 10?

Para modelos de regresión múltiple, utilizamos el valor de **Adjusted R-squared** (R-cuadrado ajustado) para evitar la inflación artificial provocada por agregar más variables. Según este valor (0.856), el modelo explica el **85.6 %** de la variabilidad de las carreras anotadas. Este modelo múltiple sí es un predictor considerablemente mejor que el modelo lineal simple de la Pregunta 10 (basado únicamente en `bat_avg`). Aquel modelo explicaba solo el 65.61 % de la variabilidad, mientras que este modelo combinado eleva esa capacidad predictiva en aproximadamente 20 puntos porcentuales.

Pregunta y Respuesta

Pregunta 14: Calcule el Factor de Inflación de la Varianza (VIF) para este modelo múltiple. Presente el código R y los resultados, e indique qué se puede concluir de este cálculo de VIF respecto de la multicolinealidad.

```
# Cargar libreria car para el calculo de VIF
library(car)

# Calcular el VIF del modelo multiple
vif(mul)
```

Salida de R:

```
> vif(mul)
   at_bats      hits    homeruns    bat_avg      wins
99.419844 1803.225223   2.234504 1195.442185   2.234290
```

Análisis de Multicolinealidad: De acuerdo con los resultados obtenidos del cálculo del VIF, existe un grave problema de multicolinealidad en este modelo. Como regla general, valores de VIF superiores a 5 o 10 indican una alta correlación entre variables predictoras, lo que vuelve inestables los coeficientes del modelo.

Se observa empíricamente que las variables hits (1803.22), bat_avg (1195.44) y at_bats (99.42) arrojan valores VIF excesivamente altos, superando por mucho el límite aceptable de 10. Esto es lógico desde un punto de vista matemático y deportivo, ya que el promedio de bateo (bat_avg) se calcula dividiendo directamente los hits entre los turnos al bate. Al incluir las tres simultáneamente, estamos ingresando información totalmente redundante al modelo, inflando la varianza de los coeficientes de forma artificial.

Pregunta y Respuesta

Pregunta 15: Construya una tabla donde indique las combinaciones de las cuatro variables utilizadas, así como el valor-p del modelo completo, el R^2 ajustado y los VIF de esas 4 variables.

A continuación se presenta el código R utilizado para generar el primer modelo de regresión lineal múltiple con cuatro variables, seguido de su respectiva comprobación de multicolinealidad:

```
# Ajuste del Modelo 1 (4 variables)
m_cuatro_1 <- lm(runs ~ at_bats + hits + homeruns + bat_avg, data = beis)
summary(m_cuatro_1)

# Calculo de VIF para el Modelo 1
library(car)
vif(m_cuatro_1)
```

Salida de la consola de R para el Modelo 1:

```
> summary(m_cuatro_1)

Call:
lm(formula = runs ~ at_bats + hits + homeruns + bat_avg, data = beis)

Residuals:
    Min       1Q   Median       3Q      Max
-41.559 -27.816  -8.172   24.474   57.496

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2387.7878   4025.4808    0.593   0.558
at_bats       -0.5125     0.7292   -0.703   0.489
hits           1.9019     2.8330    0.671   0.508
homeruns       1.2210     0.1864    6.551 7.31e-07 ***
bat_avg      -6778.6913  15727.6216   -0.431   0.670
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 31.48 on 25 degrees of freedom
Multiple R-squared:  0.8744,    Adjusted R-squared:  0.8544
F-statistic: 43.53 on 4 and 25 DF,  p-value: 6.484e-11

> vif(m_cuatro_1)
      at_bats      hits      homeruns      bat_avg
99.306739 1781.464799   1.287672 1175.904585
```

Tabla de comparación de combinaciones de cuatro variables predictoras

Modelo	Variables utilizadas	p-value	R^2 ajustado	VIF de variables
1	at_bats, hits, homeruns, bat_avg	6.48e-11	0.8544	at_bats: 99.31, hits: 1781.46, homeruns: 1.29, bat_avg: 1175.90
2	at_bats, hits, homeruns, wins	4.04e-11	0.8598	at_bats: 4.38, hits: 4.48, homeruns: 2.22, wins: 2.20
3	at_bats, hits, bat_avg, wins	3.56e-08	0.7570	at_bats: 99.35, hits: 1791.46, bat_avg: 1187.48, wins: 1.29
4	at_bats, homeruns, bat_avg, wins	4.70e-11	0.8581	at_bats: 2.89, homeruns: 2.22, bat_avg: 2.97, wins: 2.21
5	hits, homeruns, bat_avg, wins	4.52e-11	0.8585	hits: 52.43, homeruns: 2.23, bat_avg: 52.63, wins: 2.23

Pregunta y Respuesta

Pregunta 16: ¿Considera que alguno de los modelos de cuatro variables de la tabla anterior predice mejor la variable de respuesta que el modelo de cinco variables (construido en las preguntas 11-13)? ¿Cuál modelo de cuatro variables considera que es el mejor?

Sí, existen dos modelos de cuatro variables (el Modelo 2 y el Modelo 4) que son predictores muy superiores al modelo inicial de cinco variables.

El modelo de cinco variables original sufría de un problema gravísimo de multicolinealidad, lo que invalidaba estadísticamente sus coeficientes a pesar de tener un R^2 ajustado alto (0.856). Al extraer variables redundantes, observamos que el **Modelo 2** y el **Modelo 4** logran un R^2 ajustado ligeramente mayor (0.8598 y 0.8581 respectivamente), pero con la ventaja crucial de que **todos sus valores VIF caen por debajo de 5**. Esto significa que logran predecir las carreras de manera más precisa sin inflar artificialmente la varianza, cumpliendo a cabalidad con los supuestos estadísticos.

El mejor modelo de todos es el Modelo 2 (at_bats, hits, homeruns, wins). Se considera el mejor por las siguientes tres razones fundamentales:

- **Mayor poder explicativo:** Posee el R^2 ajustado más alto de toda la tabla (0.8598), lo que significa que explica casi el 86 % de la variabilidad en las carreras anotadas.
- **Multicolinealidad bajo control:** Sus valores VIF oscilan entre 2.20 y 4.48. Al mantenerse todos por debajo del umbral de 5, demuestra que cada variable aporta información valiosa e independiente.
- **Alta significancia global:** Su p-value ($4,04 \times 10^{-11}$) es estadísticamente significativo, garantizando la validez del modelo en su conjunto.

Nota: El Modelo 4 (at_bats, homeruns, bat_avg, wins) también se perfila como una alternativa estadísticamente sólida, ya que cuenta con valores VIF aún más bajos (máximo de 2.97), sacrificando únicamente una fracción mínima de su R^2 ajustado respecto al Modelo 2.